

UNIVERSIDADE FEDERAL DO CEARÁ

CAMPUS RUSSAS

CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

PEDRO HENRIQUE FERREIRA DA SILVA

RECOLORAÇÃO DE OBRAS DE ARTE PARA PORTADORES DE DALTONISMO UTILIZANDO REDES NEURAIS CONVOLUCIONAIS

RUSSAS

2025

PEDRO HENRIQUE FERREIRA DA SILVA

RECOLORAÇÃO DE OBRAS DE ARTE PARA PORTADORES DE DALTONISMO UTILIZANDO REDES NEURAIS CONVOLUCIONAIS

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Ciência da Computação do Campus Russas da Universidade Federal do Ceará, como requisito parcial à obtenção do grau de bacharel em Ciência da Computação.

Orientador: Prof. Dr. Alexandre Matos Arruda.

RUSSAS

2025

RESUMO

O daltonismo, ou deficiência na percepção de cores, afeta milhões de pessoas, limitando a capacidade de distinguir certas tonalidades e, consequentemente, dificultando a plena apreciação de obras de arte. Este trabalho propõe o desenvolvimento de uma ferramenta baseada em Redes Neurais Convolucionais para recolorir obras de arte, visando melhorar a distinção de cores para indivíduos com diferentes tipos de daltonismo, incluindo protanopia, deuteranopia, tritanopia e monocromacia, sem comprometer o significado original das obras. A metodologia utiliza uma arquitetura Pix2Pix, um modelo de rede adversarial generativa, treinada com uma abordagem não convencional. O modelo aprende a gerar uma imagem com cores adaptadas, cuja perda é calculada comparando a visão simulada de um daltônico sobre a imagem recolorida com a obra de arte original. O objetivo é treinar a rede para maximizar a distinção de características visuais enquanto preserva a naturalidade da imagem. A eficácia da solução será validada por meio de métricas quantitativas, como PSNR e SSIM, e por uma avaliação qualitativa com a participação de voluntários daltônicos. Espera-se, como resultado, obter um modelo funcional que contribua para a acessibilidade e comprove a viabilidade de uma nova estratégia de treinamento para problemas de acessibilidade visual.

Palavras-chave: Visão; Computacional; Recoloração de Imagens; Redes Neurais; Daltonismo.

ABSTRACT

Color blindness, or color vision deficiency, affects millions of people, limiting their ability to distinguish certain hues and, consequently, hindering the full appreciation of artworks. This work proposes the development of a tool based on Convolutional Neural Networks to recolor artworks, aiming to improve color distinction for individuals with different types of color blindness, including protanopia, deuteranopia, tritanopia, and monochromacy, without compromising the original meaning of the works. The methodology employs a Pix2Pix architecture, a generative adversarial network model, trained with an unconventional approach. The model learns to generate an image with adapted colors, where its loss is calculated by comparing a simulated colorblind view of the recolored output with the original artwork. The objective is to train the network to maximize the distinction of visual features while preserving the image's naturalness. The solution's effectiveness will be validated through quantitative metrics, such as PSNR and SSIM, and a qualitative assessment with the participation of colorblind volunteers. As a result, this work is expected to deliver a functional model that contributes to accessibility and proves the viability of a new training strategy for visual accessibility problems.

Keywords: Computer; Vision; Image Recoloring; Neural Networks; Color Blindness.

LISTA DE ILUSTRAÇÕES

Figura 1 – Simulações das principais variações de daltonismo 10
Figura 2 – Comparação entre o neurônio biológico e o neurônio artificial 11
Figura 3 – Exemplo de rede neural artificial com múltiplas camadas 12
Figura 4 – Ilustração simplificada de uma rede neural convolucional 14
Figura 5 – Exemplo de convolução 15
Figura 6 – Exemplos de *max pooling* e *average pooling* 16
Figura 7 – Fluxograma de uma rede adversarial generativa 17
Figura 8 – Fluxograma de uma rede *Pix2Pix* 17

LISTA DE TABELAS

Tabela 1 – Comparativo entre os trabalhos relacionados com o do autor 22
Tabela 2 – Cronograma do TCC 1 25
Tabela 3 – Cronograma do TCC 2 25

SUMÁRIO

1 INTRODUÇÃO 8
1.1 Justificativa 8
1.2 Objetivo Geral 9
1.3 Objetivos Específicos 9
1.4 Estrutura do Trabalho 9
2 FUNDAMENTAÇÃO TEÓRICA 10
2.1 Deficiência na percepção das cores 10
2.2 Redes neurais artificiais 11
2.2.1 Neurônio artificial 11
2.2.2 Arquitetura em camadas 12
2.2.3 Processo de aprendizagem 13
2.3 Redes neurais convolucionais 14
2.3.1 Camada convolucional 15
2.3.2 Camada de pooling 15
2.4 Redes adversariais generativas 16
2.4.1 Redes Pix2Pix 17
3 TRABALHOS RELACIONADOS 18
3.1 ***Recoloring image for color vision deficiency by GANs*** 18
3.2 ***Saliency consistency-based image re-colorization for color blindness*** . . . 18
3.3 ***Image recoloring of art paintings for the color blind guided by semantic segmentation*** 19
3.4 ***Image recoloring for color vision deficiency compensation using Swin Transformer*** 20
3.5 ***Color enhancement for the colorblind using color correction intensity map and Pix2Pix image conversion*** 21
3.6 Relação com o presente trabalho 22
4 METODOLOGIA 23
4.1 Coleta de imagens 23
4.2 Preparação das imagens 23
4.3 Treinamento dos modelos 24

4.4 **Avaliação dos modelos** 24
4.5 **Ferramentas e implementação** 25
4.6 **Cronograma** 25
5 **RESULTADOS ESPERADOS** 26
5.1 **Obtenção de modelos funcionais para adaptação de cores** 26
5.2 **Validação da eficácia das adaptações por meio de avaliação qualitativa** . 26
5.3 **Comprovação da viabilidade da metodologia de treinamento** 26
6 **CONCLUSÕES E TRABALHOS FUTUROS** 27
REFERÊNCIAS 28

1 INTRODUÇÃO

A visão computacional é uma subárea da inteligência artificial que tem se desenvolvido rapidamente nos últimos anos, impulsionada pelo avanço do aprendizado profundo (ZHOU *et al.*, 2023). Seu objetivo primordial é replicar a complexa capacidade humana de percepção, permitindo aos sistemas computacionais a capacidade de interpretar o mundo visual, analisando e extraindo informações relevantes de imagens e vídeos (SZELISKI, 2022).

Uma das técnicas utilizadas para visão computacional é o aprendizado profundo, que tem possibilitado a realização de tarefas que nos últimos séculos eram consideradas muito difíceis, como reconhecimento facial, veículos autônomos, autoatendimento em supermercados e diagnóstico médico assistido por computador (LI *et al.*, 2022). Essas diversas tarefas envolvem tipicamente a classificação ou síntese de imagens.

A síntese de imagens é uma área de pesquisa de grande relevância na visão computacional, com a notável capacidade de mapear padrões em imagens de um domínio para outro, preservando o conteúdo principal (LAKSHMIPRIYA *et al.*, 2025). Na prática, essa capacidade permite o desenvolvimento de soluções diversas, incluindo a conversão de imagens noturnas em diurnas, o aprimoramento de imagens médicas e a recoloração de imagens para portadores de deficiência na percepção das cores.

1.1 Justificativa

As cores desempenham um papel fundamental no cotidiano das pessoas, moldando a forma como o mundo é interpretado. No entanto, algumas pessoas nascem com uma condição chamada daltonismo, que impede a visualização adequada de determinadas cores e que não há uma cura atualmente. Essa alteração na percepção visual acompanha o indivíduo por toda a vida, fazendo com que o mundo seja percebido com uma paleta de tons mais limitada e diferente da visão convencional.

Estima-se que aproximadamente 8% dos homens e 0,5% das mulheres apresentem algum tipo de deficiência na percepção das cores, o que afeta milhões de pessoas em todo o mundo (SHARPE *et al.*, 1999). As dificuldades mais comuns envolvem a distinção entre tons de verde e vermelho, que muitas vezes perdem o contraste e parecem semelhantes ou desbotados para quem possui a condição.

Os portadores de daltonismo podem enfrentar diversas inconveniências ao longo da

Existem diversas formas de daltonismo com características diferentes. Talvez

vida devido à capacidade reduzida na discriminação das cores, como a dificuldade de interpretação de figuras e objetos em determinadas combinações de cores (CHEN *et al.*, 2024). Essa limitação coloca em desvantagem indivíduos que desejam estudar ou apreciar obras de arte, pois são capazes de distinguir apenas um conjunto restrito de cores. Dessa forma, torna-se evidente a necessidade de desenvolver ferramentas que auxiliem pessoas com daltonismo a distinguir cores de maneira mais eficaz.

1.2 Objetivo Geral

Desenvolver uma ferramenta baseada em redes neurais convolucionais, capaz de detectar e alterar cores em obras de arte para as diferentes variações de deficiência na percepção das cores, com o intuito de melhorar a distinção das cores por indivíduos com daltonismo e sem comprometer o significado original das obras.

1.3 Objetivos Específicos

- Construir uma base de dados com diversas obras de arte.
- Desenvolver filtros que simulem os diferentes tipos de daltonismo.
- Implementar modelos de redes neurais convolucionais que, com base na obra de arte e tipo de daltonismo, apliquem uma recoloração eficaz para daltônicos.
- Desenvolver uma arquitetura que permita aos modelos se auto ajustarem.
- Analisar os resultados obtidos, avaliando a eficácia dos modelos propostos.

1.4 Estrutura do Trabalho

TCCs agora são divididos em seções e não capítulos. Troca

Este trabalho está organizado em seis capítulos. No primeiro capítulo, é apresentada uma visão concisa do tema investigado pela pesquisa, uma justificativa para a sua realização e a definição dos objetivos gerais e específicos do trabalho. O segundo capítulo contém a fundamentação teórica, com todos os conceitos fundamentais para a compreensão dessa pesquisa. No terceiro capítulo, são abordados os trabalhos relacionados e uma comparação é realizada entre estes trabalhos. O quarto capítulo descreve em detalhes a metodologia que será utilizada durante a pesquisa. No quinto capítulo, são traçados os resultados esperados ao final da pesquisa. Por fim, no sexto capítulo, encontram-se as conclusões do trabalho, juntamente com as considerações finais.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os principais conceitos das técnicas que serão utilizadas na análise proposta. As seções subsequentes abordam aspectos relacionados à deficiência na percepção das cores, às redes neurais artificiais, às redes neurais convolucionais e às redes adversariais generativas, fornecendo a base teórica necessária para o desenvolvimento da pesquisa.

2.1 Deficiência na percepção das cores

A percepção das cores nos seres humanos é realizada por células fotorreceptoras localizadas na retina, conhecidas como cones (KUHN; OLIVEIRA, 2009). Esses fotorreceptores atuam na absorção dos fótons, permitindo ao sistema visual interpretar as cores com base na intensidade relativa da ativação de cada tipo de cone. Existem três tipos de cones, cada um sensível a uma faixa específica do espectro visível: cones L, cones M e cones S, que estão associados às cores vermelha, verde e azul, respectivamente (ORII *et al.*, 2016).

A disfunção de um ou mais fotorreceptores resulta na deficiência da percepção de cores, condição conhecida como daltonismo, que pode ser classificada como: tricromacia anômala, dicromacia e monocromacia (WAHAB *et al.*, 2016). A tricromacia anômala indica alterações na sensibilidade de um dos tipos de cones, enquanto a dicromacia indica a ausência de um dos tipos de cones e pode ser classificada como tritanopia, deuteranopia e protanopia, caso os cones ausentes sejam associados às cores vermelha, verde e azul, respectivamente (CHATZISTAMATIS *et al.*, 2020). A monocromacia é uma condição rara que limita a visão a uma única faixa de cor devido à ausência da maioria ou de todos os tipos de cones.

A Figura 1 simula as alterações na percepção das cores causadas pelas principais variações de daltonismo. Fica evidente que a protanopia e a deuteranopia resultam na dificuldade de distinguir entre vermelho e verde. A tritanopia, por sua vez, causa a confusão entre azul e amarelo, enquanto a monocromacia se caracteriza pela ausência total da percepção de cores.

Figura 1 – Simulações das principais variações de daltonismo



Fonte: Elaborado pelo autor (2025).

As imagens estão corretas? Tritanopia é a ausência de cone vermelho, mas a imagem apresenta

2.2 Redes neurais artificiais

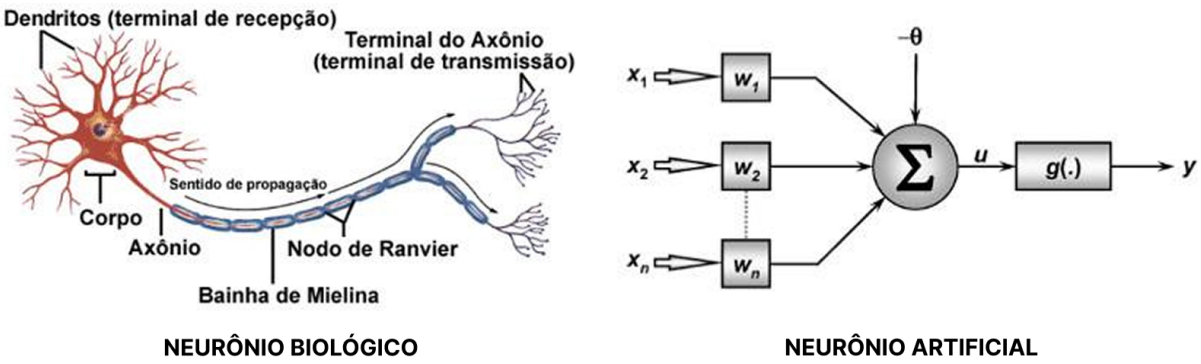
As redes neurais artificiais são modelos computacionais da área de inteligência artificial, inspirados na estrutura e no funcionamento do cérebro humano. Essencialmente, são sistemas adaptativos constituídos por unidades de processamento interconectadas, denominadas neurônios artificiais, que são organizadas em camadas e colaboram para a resolução de problemas complexos através do reconhecimento de padrões (MERGULHÃO *et al.*, 2019).

2.2.1 Neurônio artificial

O conceito de neurônio artificial foi formalizado pela primeira vez por McCulloch e Pitts (1943), estabelecendo uma analogia direta com o neurônio biológico. Dessa maneira, as entradas correspondem aos sinais que um neurônio biológico recebe através de seus dendritos; a unidade de processamento equivale ao corpo celular, onde os sinais de entrada são processados; e a saída representa o sinal transmitido pelo axônio para se conectar a outros neurônios. Essa estrutura básica, quando replicada em vasta escala e interligada por conexões com pesos ajustáveis, permite que o sistema adquira, armazene e utilize conhecimento derivado de dados para alcançar um desempenho robusto em diversas tarefas (ISLAM *et al.*, 2019).

A Figura 2 mostra uma analogia entre o neurônio biológico e o artificial. À esquerda, os dendritos do neurônio biológico recebem estímulos externos e os conduzem ao corpo celular, que integra os sinais e gera um impulso transmitido pelo axônio a outros neurônios. À direita, o neurônio artificial recebe entradas $x_1, x_2, ..., x_n$, multiplicadas por pesos $w_1, w_2, ..., w_n$, somadas, ajustadas por um limiar θ e processadas por uma função de ativação $g(\cdot)$, resultando na saída y. Assim, o neurônio artificial transforma os dados de entrada em uma resposta útil para a rede.

Figura 2 – Comparação entre o neurônio biológico e o neurônio artificial



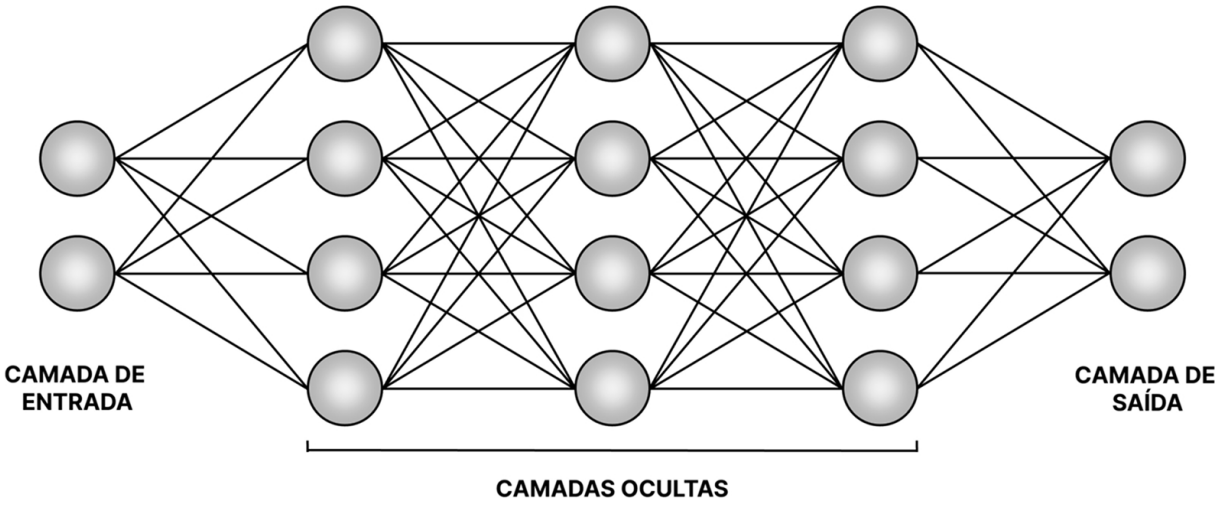
Fonte: Adaptado de Mergulhão *et al.* (2019)

2.2.2 Arquitetura em camadas

Uma rede neural artificial típica pode conter desde algumas dezenas até milhões de neurônios artificiais, organizados em uma sequência de camadas interconectadas (ISLAM *et al.*, 2019). A primeira dessas camadas é conhecida como camada de entrada, sendo responsável por receber diferentes tipos de informações do ambiente externo que a rede buscará aprender, reconhecer ou processar. Na extremidade oposta, encontra-se a camada de saída, que gera a resposta final da rede com base nas informações aprendidas. Entre essas duas extremidades, há uma ou mais camadas intermediárias chamadas camadas ocultas, nas quais ocorre o processamento interno e a extração de padrões relevantes dos dados fornecidos.

A Figura 3 ilustra um exemplo de arquitetura de rede neural artificial com múltiplas camadas. Nela, dois valores de entrada são fornecidos à camada inicial, que serve como ponto de partida para o fluxo de informações na rede. Esses dados percorrem um caminho definido, atravessando sucessivamente três camadas ocultas, cada uma composta por quatro neurônios responsáveis por transformar e combinar as informações recebidas por meio de operações matemáticas. Por fim, os dados chegam à camada de saída, composta por dois neurônios que retornam os valores finais resultantes do processamento. As conexões entre os neurônios de diferentes camadas indicam a passagem de informações, sendo que cada ligação é associada a um peso ajustado durante o processo de aprendizado.

Figura 3 – Exemplo de rede neural artificial com múltiplas camadas



Fonte: Elaborado pelo autor (2025)

2.2.3 Processo de aprendizagem

O aprendizado das redes neurais artificiais ocorre por meio de um processo de treinamento, no qual a rede ajusta os pesos de suas conexões com base em um conjunto de dados. O objetivo é que, após esse treinamento, a rede seja capaz de generalizar o conhecimento adquirido, fornecendo respostas precisas mesmo diante de dados inéditos (ROJAS, 1996). Para que isso seja possível, informações do mundo real, como textos, sons, imagens, vídeos ou séries temporais, devem ser convertidas em representações numéricas que possam ser processadas computacionalmente pela rede.

Um aspecto relevante nesse contexto é a maneira como a rede interage com o ambiente, o que define os distintos paradigmas de aprendizado. No aprendizado supervisionado, um agente externo fornece à rede a resposta esperada para cada entrada, permitindo que os pesos sejam ajustados com base nessa correção explícita. No aprendizado não supervisionado, não há indicação externa das respostas corretas, cabendo à rede identificar padrões e estruturas nos dados por meio da análise das regularidades presentes. Já no aprendizado por reforço, um avaliador externo examina a qualidade da resposta gerada pela rede e fornece sinais que orientam o ajuste progressivo dos parâmetros ao longo do tempo (MORALES; ESCALANTE, 2022).

No contexto do aprendizado supervisionado, uma das técnicas mais utilizadas para o ajuste dos pesos sinápticos é o *backpropagation*. Esse método é responsável pelo cálculo dos gradientes necessários para a atualização dos parâmetros internos durante o treinamento. O nome deriva do processo de redistribuição do erro, que é inicialmente calculado na saída da rede e, em seguida, retroagido camada por camada, permitindo que cada peso seja ajustado com base na sua contribuição para o resultado final. Essa técnica garante que a rede aprenda a minimizar uma função de perda, aproximando suas respostas das saídas esperadas (ISLAM *et al.*, 2019).

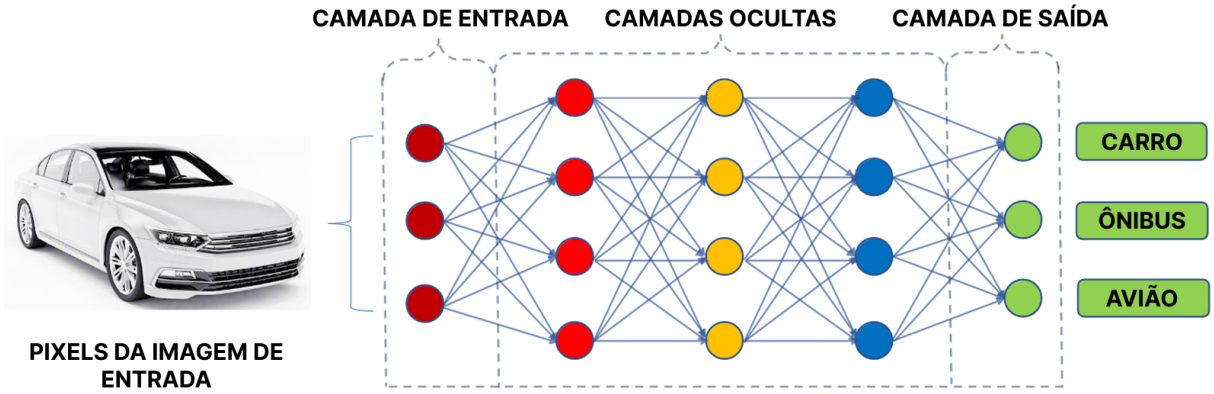
O *backpropagation* é uma extensão da chamada regra delta, utilizada em arquiteturas com múltiplas camadas, e baseia-se na regra da cadeia da matemática para estimar de forma eficiente os gradientes parciais. Está relacionada a métodos como o algoritmo de Gauss-Newton e pode ser interpretada como um caso específico de uma abordagem mais ampla chamada diferenciação automática (ROJAS, 1996). Durante o treinamento, é geralmente utilizada em conjunto com o algoritmo de descida do gradiente, que realiza ajustes sucessivos nos pesos da rede, sempre na direção que mais reduz o erro entre a saída produzida e a resposta correta.

2.3 Redes neurais convolucionais

As redes neurais convolucionais são uma classe de redes neurais de alta performance, especialmente eficazes em tarefas de reconhecimento de imagem. Sua arquitetura é projetada para extrair automaticamente características relevantes de uma imagem por meio de uma sequência de camadas convolucionais e de *pooling* (KRICHEN, 2023). Essas características são então utilizadas por camadas finais, totalmente conectadas, para realizar uma predição. O treinamento de uma rede neural convolucional exige um vasto conjunto de imagens rotuladas, onde o modelo aprende a associar os padrões visuais extraídos com seus respectivos rótulos, utilizando o algoritmo *backpropagation* (HABIB; QURESHI, 2022). Com isso, a rede se torna capaz de classificar imagens novas, nunca antes vistas, ao processá-las e selecionar o rótulo com a maior probabilidade resultante.

A Figura 4 ilustra o fluxo de uma rede neural convolucional usada para classificação. A imagem de um carro, ao ser introduzida na rede, passa por uma série de camadas ocultas. As camadas iniciais aplicam filtros para detectar padrões simples, como bordas e texturas. À medida que a informação avança para camadas mais profundas, os filtros passam a identificar características mais complexas e abstratas. O conjunto final de características é então enviado para a camada de saída, que calcula uma distribuição de probabilidade entre as classes possíveis: carro, ônibus e avião. A decisão da rede baseia-se na classe que obtém a maior probabilidade. É por meio da retropropagação que os pesos de todos esses filtros são ajustados de forma iterativa, minimizando o erro entre as previsões do modelo e as respostas corretas.

Figura 4 – Ilustração simplificada de uma rede neural convolucional



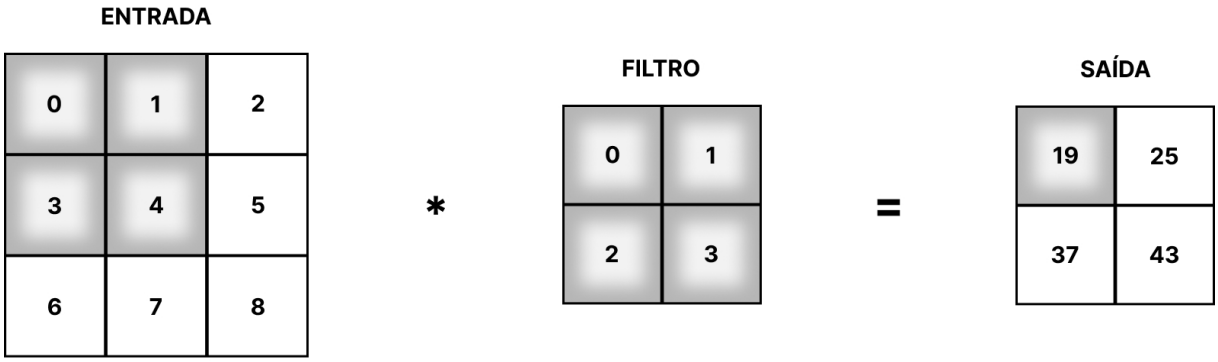
Fonte: Traduzido de Krichen (2023)

2.3.1 Camada convolucional

A camada convolucional é o principal elemento de uma rede neural convolucional, sendo responsável pela extração de padrões visuais. Sua operação consiste em aplicar uma convolução sobre os dados de entrada utilizando um conjunto de filtros aprendíveis. Cada filtro, que é uma pequena matriz de pesos, desliza sobre a entrada e calcula o produto escalar entre seus valores e as regiões correspondentes. O resultado deste processo é um conjunto de mapas de características, onde cada mapa codifica a localização e a intensidade de um atributo específico que o respectivo filtro foi treinado para detectar (KRICHEN, 2023).

A Figura 5 mostra um exemplo desse processo, em que um filtro percorre a imagem de entrada e produz uma saída com valores que refletem os padrões identificados em cada região.

Figura 5 – Exemplo de convolução



Fonte: Elaborado pelo autor (2025)

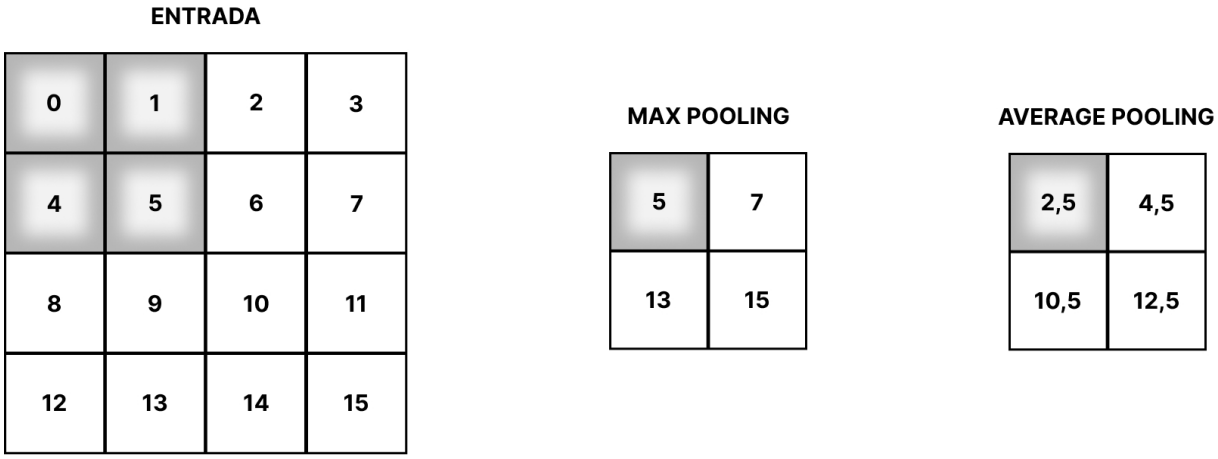
2.3.2 Camada de pooling

Corrigir divisão silábica.

A camada de *pooling*, também conhecida como camada de agrupamento ou subamostragem, tem a função principal de reduzir a dimensionalidade espacial dos mapas de características gerados pelas camadas convolucionais. O processo consiste em aplicar, independentemente, a cada mapa, uma operação que sumariza as informações de pequenas regiões não sobrepostas. As estratégias mais comuns são o *max pooling*, que extrai o valor de maior ativação da região, e o *average pooling*, que calcula a média. Este mecanismo oferece duas vantagens cruciais: a redução da carga computacional para as camadas subsequentes e a criação de um grau de invariância a pequenas translações, o que torna a rede mais robusta (KRICHEN, 2023).

A Figura 6 mostra um exemplo desse processo, em que a entrada passa pelo *max pooling* e pelo *average pooling*, resultando em uma versão mais compacta da imagem original.

Figura 6 – Exemplos de *max pooling* e *average pooling*



Fonte: Elaborado pelo autor (2025)

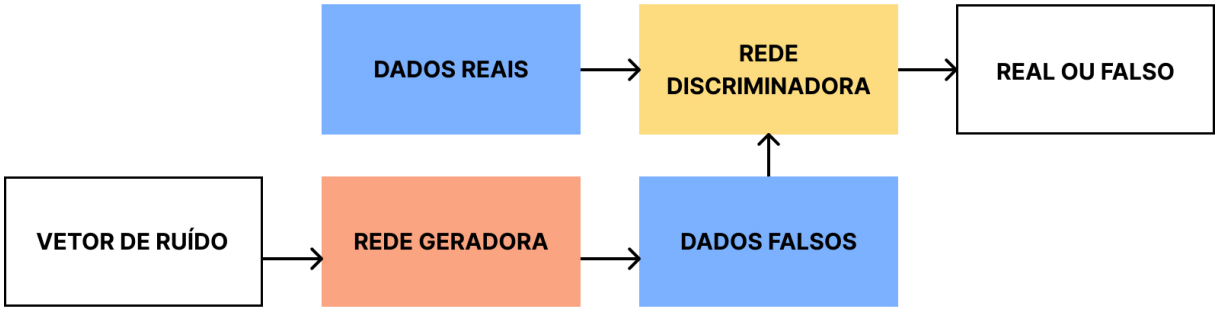
2.4 Redes adversariais generativas

As redes adversariais generativas têm como propósito principal gerar dados sintéticos que sejam visualmente e estatisticamente indistinguíveis de um conjunto de dados reais. Para isso, utilizam uma abordagem baseada na teoria dos jogos, envolvendo duas redes neurais com funções opostas: a Geradora e a Discriminadora. A Geradora tenta criar amostras que se assemelhem ao conjunto de treinamento, enquanto a Discriminadora busca identificar se essas amostras são autênticas ou produzidas artificialmente. Essa relação competitiva impulsiona o aprimoramento contínuo de ambas as redes (GOODFELLOW *et al.*, 2020).

O treinamento ocorre de forma simultânea e interdependente. A Discriminadora é ajustada para reconhecer os dados reais e rejeitar os falsos, funcionando como um classificador binário. Já a Geradora é otimizada para confundir a Discriminadora, gerando exemplos cada vez mais convincentes. Esse ciclo de oposição evolui até que as amostras sintéticas se tornem tão realistas que a Discriminadora não consiga mais diferenciá-las com precisão, atribuindo a qualquer entrada uma probabilidade próxima de 50% de ser real (GOODFELLOW *et al.*, 2020).

A Figura 7 representa esse funcionamento. Um vetor de ruído é fornecido à Geradora, que produz dados artificiais. Essas amostras, combinadas com os exemplos reais, são então analisadas pela Discriminadora, que tenta classificá-las como verdadeiras ou falsas. Os erros cometidos por ambas as redes durante o treinamento são minimizados por meio da atualização iterativa de seus pesos, utilizando o algoritmo de *backpropagation*. Com o tempo, esse processo competitivo leva a Geradora a alcançar seu objetivo: produzir dados sintéticos de alta qualidade, praticamente indistinguíveis dos originais.

Figura 7 – Fluxograma de uma rede adversarial generativa



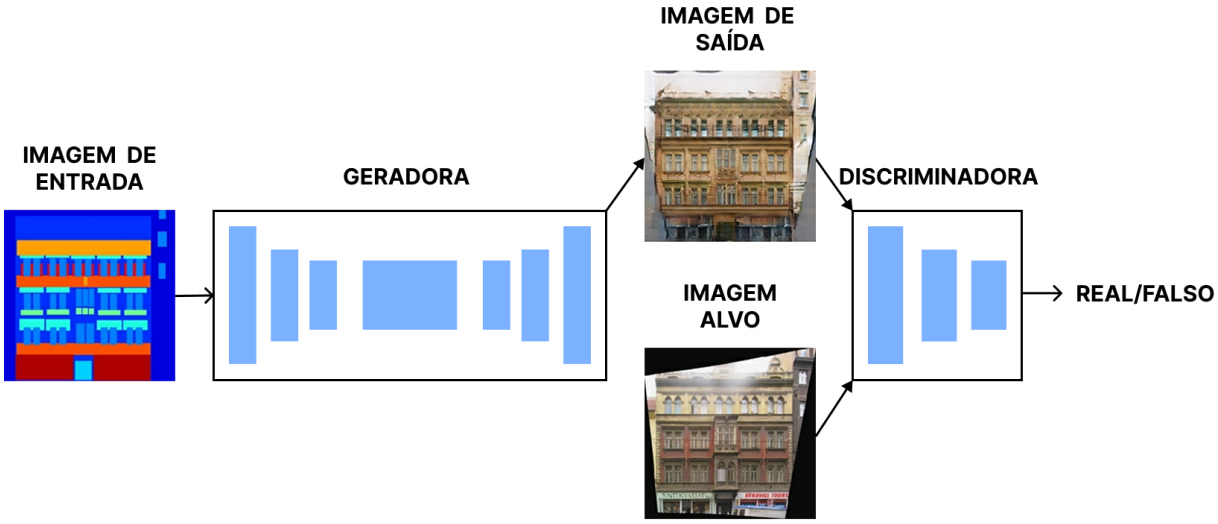
Fonte: Elaborado pelo autor (2025)

2.4.1 Redes Pix2Pix

As redes *Pix2Pix* são um tipo de arquitetura baseada em redes adversariais generativas voltada para tarefas de tradução de imagem para imagem. Diferente das redes generativas tradicionais, que geram imagens a partir de vetores de ruído, o *Pix2Pix* é um modelo condicional, o que significa que a geração de imagens é guiada por uma imagem de entrada. Essa abordagem permite transformar uma imagem de um domínio em outra de domínio relacionado, mantendo a correspondência estrutural (HENRY *et al.*, 2021).

A Figura 8 mostra o funcionamento da arquitetura *Pix2Pix*. A imagem de entrada é processada por uma rede geradora que produz uma imagem no domínio de destino. Em seguida, uma rede discriminadora avalia se a imagem gerada se assemelha à imagem real. Durante o treinamento, a geradora busca enganar a discriminadora, gerando saídas cada vez mais realistas e coerentes.

Figura 8 – Fluxograma de uma rede *Pix2Pix*



Fonte: Elaborado pelo autor (2025).

3 TRABALHOS RELACIONADOS

Este capítulo apresenta uma análise de estudos previamente realizados que apresentam similaridades com a presente pesquisa, devido à sua relevância temática e alinhamento com o objetivo de recolorir imagens para auxiliar os portadores de daltonismo. A análise será dividida em cinco seções principais, cada uma detalhando um estudo relevante na área, e culminará em uma sexta seção que discute a relação entre esses estudos e a presente pesquisa.

3.1 *Recoloring image for color vision deficiency by GANs*

Zhang *et al.* (2019) apresentaram uma técnica de recoloração de imagens com o objetivo de ajudar pessoas com deficiência na percepção das cores, especialmente nos casos de protanopia e deuteranopia. A proposta se baseia em redes adversariais generativas, utilizando um modelo chamado *BicycleGAN* com a introdução de novos módulos que tornam o processo de recoloração mais eficiente e natural.

O modelo conta com três componentes principais: (i) um módulo de simulação de daltonismo, que permite avaliar a imagem como seria vista por uma pessoa com deficiência visual cromática; (ii) um módulo de conversão para escala de cinza, que ajuda a preservar os contornos e formas da imagem, reduzindo distrações causadas por ruídos de cor; e (iii) um módulo condicional, que identifica as cores mais importantes da imagem e calcula a distância entre essas cores na versão original e recolorida, orientando o modelo a preservar a aparência natural.

A abordagem foi avaliada com base em um conjunto de imagens específicas para daltonismo e comparada com outras arquiteturas conhecidas, como *Pix2Pix*, *CycleGAN* e o próprio *BicycleGAN* original. Os resultados mostraram que o método proposto produziu imagens com melhor distinção visual para daltônicos e maior preservação da naturalidade, obtendo os melhores índices de similaridade estrutural entre imagem original e recolorida.

3.2 *Saliency consistency-based image re-colorization for color blindness*

Li *et al.* (2020) desenvolveram um método de recoloração de imagens que busca preservar as regiões mais importantes da imagem, chamadas de regiões salientes, para pessoas com daltonismo. Os autores observaram que muitas técnicas de correção de cor acabam alterando essas regiões de destaque, dificultando que pessoas daltônicas percebam corretamente os

elementos mais relevantes. O objetivo do trabalho é garantir que essas partes continuem visíveis tanto para quem enxerga normalmente quanto para quem tem daltonismo.

A metodologia utiliza uma abordagem baseada em imagem de referência. Primeiro, o sistema usa técnicas de recuperação de imagem para encontrar um conjunto de imagens com conteúdo e semântica semelhantes à imagem que precisa de correção. Em seguida, um algoritmo é aplicado para detectar as áreas de interesse visual em todo o conjunto, permitindo identificar qual imagem mantém suas regiões salientes mais consistentes após a simulação de visão daltônica. Essa imagem, cujo esquema de cores é menos afetado pela simulação, é selecionada como imagem de referência. Finalmente, a imagem original a ser corrigida é convertida para escala de cinza e, então, recolorida com base no esquema de cores da imagem de referência utilizando uma rede neural convolucional, tornando assim sua paleta de cores mais perceptível para pessoas daltônicas.

A eficácia do método foi validada por comparações qualitativas e por uma avaliação subjetiva com sete participantes daltônicos, que precisaram identificar as regiões salientes em imagens processadas por cinco métodos diferentes. O método proposto obteve a maior taxa de acerto na identificação correta dessas regiões, superando significativamente os outros quatro métodos avaliados. Os resultados confirmam que a abordagem baseada na consistência da saliência e no uso de imagem de referência é eficaz para preservar a percepção do conteúdo principal por pessoas com daltonismo.

3.3 *Image recoloring of art paintings for the color blind guided by semantic segmentation*

Chatzistamatis *et al.* (2020) elaboraram um método de recoloração de obras de arte digitalizadas voltado à acessibilidade visual para indivíduos com deficiência na percepção de cores, especialmente protanopia e deuteranopia. O objetivo é aprimorar a distinção de cores sem comprometer a aparência natural da obra original para observadores com visão normal. Para isso, a proposta utiliza segmentação semântica, baseada em uma rede neural profunda com aprendizado por transferência, extraindo objetos relevantes na pintura para aplicar a correção de cor apenas em áreas de interesse.

A segmentação divide a imagem em dois grupos: um contendo os objetos de interesse (pessoas, barcos, pássaros, cavalos, tigelas, cadeiras, mesas, vasos e frutas) e outro com o restante da cena. As cores associadas aos objetos de interesse são simuladas conforme seriam percebidas por um daltônico, e apenas aquelas cuja alteração causa confusão perceptiva são selecionadas

para modificação. As demais cores são mantidas inalteradas, minimizando o número de *pixels* modificados e preservando a naturalidade da imagem. O processo de recoloração aplica uma transformação vetorial guiada por uma função-objetivo composta por três termos: preservação da distinção entre cores relevantes, manutenção da diferença entre cores de objetos e fundo, e proximidade da nova cor em relação à original. A otimização dessa função é realizada com o algoritmo de evolução diferencial, ajustando os parâmetros de transformação de cor.

O método foi avaliado em seis pinturas e comparado a dois algoritmos existentes. Os resultados, tanto qualitativos quanto quantitativos, indicaram que a abordagem proposta superou os métodos concorrentes na maioria dos casos, gerando imagens esteticamente agradáveis e mais acessíveis para pessoas daltônicas, ao mesmo tempo em que mantém a integridade visual da obra para observadores normais.

3.4 *Image recoloring for color vision deficiency compensation using Swin Transformer*

Chen *et al.* (2024) formularam um método baseado em redes neurais profundas para a recoloração de imagens com foco em melhorar simultaneamente o contraste das cores percebido por indivíduos daltônicos e a naturalidade da imagem para indivíduos com visão normal. O trabalho aborda limitações de métodos anteriores que não conciliam bem esses dois aspectos e que possuem custo computacional elevado, inviabilizando o uso em tempo real. A principal inovação está na combinação de uma arquitetura com blocos *Swin Transformer* e em um processo de treinamento não supervisionado, dispensando a necessidade de imagens de referência.

O modelo é treinado com uma função de perda personalizada que considera três componentes: contraste local, contraste global e naturalidade, esta última medida pelo índice de similaridade estrutural. A arquitetura substitui as camadas convolucionais tradicionais por *Swin Transformers*, que capturam dependências de longo alcance e oferecem melhor desempenho com menor custo computacional. A entrada da rede é um conjunto de imagens cuidadosamente selecionadas ou sintetizadas para conter pares de cores difíceis de distinguir por indivíduos com daltonismo. O modelo realiza a extração hierárquica de características na etapa de codificação e reconstrói a imagem recolorida por meio de um decodificador, mantendo resolução e detalhes.

Os experimentos quantitativos, qualitativos e subjetivos, que contaram com a participação de 18 voluntários daltônicos, demonstraram que o modelo proposto é competitivo com os principais métodos da literatura, superando-os em diversos cenários tanto em contraste

quanto em naturalidade. Modelos treinados com diferentes pesos de naturalidade mostraram desempenho ajustável conforme a necessidade de equilíbrio entre contraste e fidelidade visual. O tempo médio de processamento superou drasticamente os métodos anteriores. Os autores concluem que o modelo proposto é uma solução eficaz, eficiente e adaptável para aplicações em tempo real de compensação visual para pessoas com daltonismo.

3.5 *Color enhancement for the colorblind using color correction intensity map and Pix2Pix image conversion*

Komatsu e Kubota (2024) propuseram um método de aprimoramento de imagens voltado para pessoas com daltonismo, em especial aquelas com deuteranopia, visando resolver o problema da falta de naturalidade presente em abordagens anteriores de correção de cor. Para isso, o método combina um mapa de intensidade de correção de cor com um modelo de aprendizado profundo baseado no *Pix2Pix*.

O mapa de intensidade de correção de cor é gerado a partir da análise das componentes cromáticas, que identifica direções no diagrama cromático onde indivíduos daltônicos têm maior dificuldade em perceber variações de cor. O mapa estima, *pixel* a *pixel*, onde a correção de cor é necessária, priorizando regiões com maior discrepância perceptiva entre pessoas com e sem daltonismo. Em seguida, um modelo *Pix2Pix* é treinado para aprender a reverter imagens degradadas de volta à sua forma perceptivamente mais clara. A imagem final é obtida por meio de uma mesclagem entre a imagem original e a imagem corrigida, com pesos definidos pelo mapa de intensidade de correção de cor, garantindo que apenas regiões críticas sejam modificadas.

Os resultados foram avaliados por meio da criação de imagens que simulam a visão de um daltônico, tanto para a imagem original quanto para a imagem corrigida. As simulações demonstraram que elementos antes indistinguíveis tornaram-se mais fáceis de distinguir após a aplicação do método, inclusive em testes com diferentes valores de correção, demonstrando flexibilidade para aplicações em contextos visuais variados, como sites, pôsteres e materiais gráficos. Além disso, as imagens corrigidas mantiveram uma aparência natural para observadores com visão normal. O estudo conclui que a combinação de um mapa de intensidade com um modelo de aprendizagem profunda permite uma correção de cor eficaz para daltônicos, sem comprometer a naturalidade da imagem original.

3.6 Relação com o presente trabalho

Os cinco estudos analisados fornecem uma base relevante para o desenvolvimento deste trabalho, demonstrando a variedade das técnicas de recoloração de imagens para pessoas daltônicas. As abordagens investigadas abrangem desde métodos de otimização até o uso de diversas arquiteturas de redes neurais, cada uma com estratégias distintas para conciliar a correção de cor com a preservação da naturalidade e da percepção visual.

O trabalho de Chatzistamatis *et al.* (2020) introduz a recoloração seletiva em obras de arte por meio da segmentação semântica. Li *et al.* (2020) priorizam a consistência da saliência, utilizando uma imagem de referência para garantir que o foco visual seja o mesmo para todos os observadores. No campo das redes generativas, Zhang *et al.* (2019) aprimoram a arquitetura *BicycleGAN* com módulos de restrição; Komatsu e Kubota (2024) combinam um mapa de intensidade de correção com o modelo *Pix2Pix* para uma modificação localizada; Chen *et al.* (2024), por sua vez, inovam ao aplicar uma arquitetura *Swin Transformer* com treinamento não supervisionado, apresentando um excelente desempenho em tempo real.

Este trabalho se concentrará na recoloração de obras de arte digitalizadas, um nicho de aplicação introduzido por Chatzistamatis *et al.* (2020). Diferentemente da abordagem baseada em segmentação semântica, o projeto desenvolverá uma rede neural convolucional com a arquitetura *Pix2Pix* para realizar a tarefa de recoloração. Em contraste com os trabalhos analisados, que focam primariamente em deuteranopia e protanopia, esta proposta amplia o escopo para incluir também a tritanopia e a monocromacia, oferecendo uma solução mais abrangente.

A Tabela 1 compara os cinco estudos de referência com este trabalho, avaliando cada um com base na tecnologia utilizada, no foco em obras de arte e na inclusão das deficiências de tritanopia e monocromacia.

Tabela 1 – Comparativo entre os trabalhos relacionados com o do autor

Trabalho	**Tecnologia**	**Obras de Arte**	**Tritanopia e Monocromacia**
Zhang *et al.* (2019)	*BicycleGAN*	Não	Não
Li *et al.* (2020)	Recuperação de Imagem	Não	Não
Chatzistamatis *et al.* (2020)	Segmentação Semântica	Sim	Não
Chen *et al.* (2024)	*Swin Transformer*	Não	Não
Komatsu e Kubota (2024)	*Pix2Pix*	Não	Não
Este Trabalho	***Pix2Pix***	**Sim**	**Sim**

Fonte: Elaborado pelo autor (2025).

O que torna imagens de obras de arte diferentes das utilizadas nos trabalhos que não focaram neste nicho? Ex

4 METODOLOGIA

Neste capítulo, é descrita a metodologia que será adotada no desenvolvimento desta pesquisa, que consiste na recoloração de obras de arte para portadores de daltonismo utilizando redes neurais convolucionais.

4.1 Coleta de imagens

A etapa inicial do trabalho consiste na obtenção das imagens que servirão de base para o treinamento e a avaliação dos modelos desenvolvidos. Para isso, será utilizada uma base de dados disponível publicamente no site <https://www.kaggle.com/datasets/ikarus777/best-artworks-of-all-time>, que reúne uma ampla coleção de obras de arte de diversos artistas renomados.

A escolha dessa base de dados justifica-se por sua expressiva diversidade de estilos, autores e composições visuais, o que contribui significativamente para a representatividade e a complexidade do conjunto de dados. Além disso, seu volume superior a 2 GB de conteúdo garante uma quantidade substancial de exemplos, favorecendo um treinamento mais robusto e eficaz dos modelos propostos.

4.2 Preparação das imagens

Como? Se as técnicas anteriores não distinguem todos os tipos d

Para preparar as imagens coletadas para o treinamento, será executada uma etapa de pré-processamento e filtragem. Primeiramente, todas as obras serão padronizadas para a resolução de 1000x1000 pixels, visando a compatibilidade com a arquitetura da rede e a consistência dos dados. Subsequentemente, será realizada uma filtragem criteriosa para descartar as imagens que não sofrem alterações perceptíveis sob uma simulação de daltonismo, garantindo que o modelo treine apenas com exemplos relevantes e visualmente impactantes.

Após a filtragem, o conjunto de imagens remanescente será expandido por meio de técnicas de aumento de dados. Serão aplicadas transformações geométricas, como rotações e inversões, com o objetivo de multiplicar a diversidade e o volume dos dados de treinamento. Este procedimento é fundamental para aumentar a robustez do modelo e sua capacidade de generalização para obras de arte que não foram vistas durante o treinamento.

4.3 Treinamento dos modelos

O treinamento será realizado com uma arquitetura *Pix2Pix*, mas com um fluxo de dados e objetivo de aprendizado não convencionais. O Gerador da rede receberá a imagem original como entrada e produzirá uma imagem com cores adaptadas. A principal inovação reside no cálculo da perda: a imagem recolorida pelo Gerador passará por um filtro de simulação de daltonismo, e o resultado será então comparado com a imagem original. O objetivo é que a rede aprenda a escolher novas cores que, mesmo após a simulação, preservem a distinção entre os elementos visuais que eram perceptíveis na obra original.

A função de penalidade do Gerador será, portanto, projetada para maximizar a distinção de características na imagem simulada, em vez de buscar uma correspondência literal de *pixels*. Isso pode ser alcançado com uma perda perceptual ou de contraste. Simultaneamente, o Discriminador da arquitetura *Pix2Pix* desempenhará um papel crucial ao garantir que as imagens recoloridas mantenham a naturalidade e o estilo de uma obra de arte, evitando que o Gerador crie soluções com cores visualmente anômalas. O treinamento otimizará, assim, um balanço entre a robustez das cores e o realismo estético da imagem gerada.

4.4 Avaliação dos modelos

A avaliação quantitativa medirá a fidelidade das imagens geradas em relação às originais por meio de métricas objetivas. Serão utilizados o *Peak Signal-to-Noise Ratio (PSNR)* para aferir a qualidade da reconstrução e o *Structural Similarity Index Measure (SSIM)* para comparar a similaridade estrutural entre as imagens. Resultados superiores nessas métricas indicarão uma recoloração de alta precisão.

Para a avaliação qualitativa, será realizado um estudo com voluntários, incluindo portadores de daltonismo, para validar a eficácia prática da solução. Os participantes avaliarão as imagens recoloridas, comparando-as com as originais, por meio de questionários que abordarão critérios como a naturalidade das cores, a distinção visual entre elementos e a preferência estética. A análise das respostas deste público-alvo será fundamental para determinar se o método proposto melhora efetivamente a experiência de apreciação das obras.

Em nenhum lugar da metodolia é afirmado como será feita a distinção do tipo de dautonismo. Será u

4.5 Ferramentas e implementação

Os modelos serão desenvolvidos utilizando a biblioteca *PyTorch* da linguagem *Python*, permitindo uma implementação eficiente de redes neurais *Pix2Pix*. O ambiente de desenvolvimento e experimentação será a plataforma Google Colab, escolhida por sua acessibilidade e pela disponibilidade de Unidades de Processamento Gráfico de alto desempenho, que são essenciais para acelerar o processo de treinamento com um grande volume de imagens em alta resolução.

Para a execução do projeto, serão utilizadas outras bibliotecas fundamentais do ecossistema *Python*, como a *OpenCV* e a *Pillow* para a manipulação de imagens e para a implementação dos filtros de simulação de daltonismo. A biblioteca *NumPy* será empregada para operações numéricas eficientes, enquanto a *Matplotlib* e a *Seaborn* serão usadas para a visualização de dados e a geração dos gráficos de resultados.

4.6 Cronograma

O desenvolvimento do trabalho será dividido em duas etapas, distribuídas entre o TCC 1 e o TCC 2, conforme demonstrado nas tabelas a seguir.

Tabela 2 – Cronograma do TCC 1

Atividades	**Abr**	**Mai**	**Jun**	**Jul**
Procura de trabalhos relacionados	X	X		
Escrita da introdução			X	
Escrita dos objetivos			X	
Escrita da fundamentação teórica			X	
Escrita dos trabalhos relacionados		X		
Escrita da metodologia				X
Escrita dos resultados esperados				X

Fonte: Elaborado pelo autor (2025)

Tabela 3 – Cronograma do TCC 2

Atividades	**Set**	**Out**	**Nov**	**Dez**	**Jan**
Coleta das imagens	X				
Implementação dos modelos		X			
Treinamento dos modelos			X		
Avaliação dos modelos			X		
Escrita dos resultados				X	
Revisão final					X
Defesa do trabalho final					X

Fonte: Elaborado pelo autor (2025)

5 RESULTADOS ESPERADOS

Este capítulo detalha os resultados almejados com a aplicação da metodologia descrita. A expectativa é que o uso de uma abordagem de treinamento não convencional, focada na percepção daltônica, produza uma solução eficaz e inovadora para a adaptação de cores em obras de arte.

5.1 Obtenção de modelos funcionais para adaptação de cores

O principal resultado esperado é o desenvolvimento de um modelo de rede neural, baseado na arquitetura *Pix2Pix*, plenamente treinado e funcional. Espera-se que este modelo seja capaz de receber como entrada uma obra de arte original e gerar uma nova versão com cores adaptadas. O objetivo é que a imagem resultante, embora esteticamente agradável, seja fundamentalmente otimizada para que seus elementos visuais se tornem mais distintos quando percebidos por um indivíduo com daltonismo.

5.2 Validação da eficácia das adaptações por meio de avaliação qualitativa

A comprovação do sucesso do projeto virá, majoritariamente, da avaliação qualitativa. A expectativa é que os participantes da pesquisa com daltonismo relatem uma melhora significativa na distinção de formas, contornos e detalhes nas imagens processadas pelo modelo, em comparação com sua percepção das obras originais. Espera-se que os questionários aplicados confirmem que a adaptação de cores torna a experiência de apreciação artística mais rica e informativa para este público, validando a eficácia prática da solução proposta.

5.3 Comprovação da viabilidade da metodologia de treinamento

Um resultado fundamental será a demonstração de que a metodologia de treinamento proposta é viável e eficaz. Ao penalizar o modelo com base na análise da sua imagem de saída após passar por um filtro de simulação de daltonismo, almeja-se provar que é possível instruir uma rede neural a otimizar uma imagem para uma percepção específica. Espera-se que os resultados demonstrem que essa abordagem não convencional é uma estratégia promissora para resolver problemas complexos de acessibilidade visual, constituindo a principal contribuição científica deste trabalho.

6 CONCLUSÕES E TRABALHOS FUTUROS

Este trabalho estabeleceu as bases conceituais e estratégicas para um projeto que busca, por meio da inteligência artificial, promover uma maior inclusão no acesso à arte. O estudo partiu do desafio enfrentado por pessoas com daltonismo na apreciação de obras e consolidou, nesta primeira fase, um plano de pesquisa estruturado para o desenvolvimento de uma solução tecnológica que remete diretamente este problema.

A principal contribuição desta etapa foi a concepção de uma abordagem original para o tratamento do problema. Em vez de restaurar cores de forma literal, o método proposto visa ensinar um modelo computacional a antecipar a percepção daltônica e, a partir disso, adaptar as imagens de forma proativa, realçando as distinções visuais que seriam perdidas. A estrutura para a validação empírica dessa ideia foi detalhada, criando um roteiro claro para a fase experimental.

A próxima etapa do projeto (TCC II) focará na transição da teoria para a prática. O roteiro metodológico será implementado para gerar a solução computacional e submetê-la a testes rigorosos, especialmente por meio da avaliação direta com o público-alvo. Espera-se, com isso, não apenas validar a eficácia da abordagem proposta, mas também entregar uma contribuição tangível ao campo da tecnologia assistiva, demonstrando o potencial de novas técnicas de aprendizado de máquina para a promoção da acessibilidade cultural.

REFERÊNCIAS

CHATZISTAMATIS, S.; RIGOS, A.; TSEKOURAS, G. E. Image recoloring of art paintings for the color blind guided by semantic segmentation. In: ILIADIS, L.; ANGELOV, P. P.; JAYNE, C.; PIMENIDIS, E. (Ed.). **Proceedings of the 21st EANN (Engineering Applications of Neural Networks) 2020 Conference**. Cham: Springer International Publishing, 2020. p. 261–273. ISBN 978-3-030-48791-1.

CHEN, L.; ZHU, Z.; HUANG, W.; GO, K.; CHEN, X.; MAO, X. Image recoloring for color vision deficiency compensation using swin transformer. **Neural Computing and Applications**, Springer, v. 36, n. 11, p. 6051–6066, 2024.

GOODFELLOW, I.; POUGET-ABADIE, J.; MIRZA, M.; XU, B.; WARDE-FARLEY, D.; OZAIR, S.; COURVILLE, A.; BENGIO, Y. Generative adversarial networks. **Communications of the ACM**, ACM New York, NY, USA, v. 63, n. 11, p. 139–144, 2020.

HABIB, G.; QURESHI, S. Optimization and acceleration of convolutional neural networks: A survey. **Journal of King Saud University-Computer and Information Sciences**, Elsevier, v. 34, n. 7, p. 4244–4268, 2022.

HENRY, J.; NATALIE, T.; MADSEN, D. Pix2pix gan for image-to-image translation. **Research Gate Publication**, p. 1–5, 2021.

ISLAM, M.; CHEN, G.; JIN, S. An overview of neural network. **American Journal of Neural Networks and Applications**, Science Publishing Group, v. 5, n. 1, p. 7–11, 2019.

KOMATSU, S.; KUBOTA, A. Color enhancement for the colorblind using color correction intensity map and pix2pix image conversion. In: **2024 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)**. [*S. l.*: *s. n.*], 2024. p. 1–5.

KRICHEN, M. Convolutional neural networks: A survey. **Computers**, MDPI, v. 12, n. 8, p. 151, 2023.

KUHN, G.; OLIVEIRA, M. Recoloração de imagens para portadores de deficiência na percepção de cores. In: **Anais do XXII Concurso de Teses e Dissertações**. Porto Alegre, RS, Brasil: SBC, 2009. p. 113–120. ISSN 2763-8820. Disponível em: https://sol.sbc.org.br/index.php/ctd/article/view/33772.

LAKSHMIPRIYA, B.; SINGH, P. K.; JAYALAKSHMY, S. Pix2pix gan for image-to-image translation: A comparative study with diverse datasets. **Harnessing Generative AI: Disruptive Technologies for Innovative Applications**, John Wiley & Sons, p. 73, 2025.

LI, J.; FENG, X.; FAN, H. Saliency consistency-based image re-colorization for color blindness. **IEEE Access**, v. 8, p. 88558–88574, 2020.

LI, Z.; LIU, F.; YANG, W.; PENG, S.; ZHOU, J. A survey of convolutional neural networks: Analysis, applications, and prospects. **IEEE Transactions on Neural Networks and Learning Systems**, v. 33, n. 12, p. 6999–7019, 2022.

MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. **The bulletin of mathematical biophysics**, Springer, v. 5, n. 4, p. 115–133, 1943.

MERGULHÃO, E.; ANDRADE, S.; NASCIMENTO, J. do. Um modelo computacional baseado em redes neurais artificiais para auxiliar o reconhecimento de cores por portadores de daltonismo. **Blucher Physics Proceedings**, v. 6, n. 1, p. 61–66, 2019.

MORALES, E. F.; ESCALANTE, H. J. Chapter 6 - a brief introduction to supervised, unsupervised, and reinforcement learning. In: TORRES-GARCíA, A. A.; REYES-GARCíA, C. A.; VILLASEñOR-PINEDA, L.; MENDOZA-MONTOYA, O. (Ed.). **Biosignal Processing and Classification Using Computational Learning and Intelligence**. Academic Press, 2022. p. 111–129. ISBN 978-0-12-820125-1. Disponível em: https://www.sciencedirect.com/science/article/pii/B9780128201251000178.

ORII, H.; KAWANO, H.; SUETAKE, N.; MAEDA, H. Color conversion for color blindness employing multilayer neural network with perceptual model. In: BRÄUNL, T.; MCCANE, B.; RIVERA, M.; YU, X. (Ed.). **Image and Video Technology**. Cham: Springer International Publishing, 2016. p. 3–14. ISBN 978-3-319-29451-3.

ROJAS, R. The backpropagation algorithm. In: ____. **Neural Networks: A Systematic Introduction**. Berlin, Heidelberg: Springer Berlin Heidelberg, 1996. p. 149–182. ISBN 978-3-642-61068-4. Disponível em: https://doi.org/10.1007/978-3-642-61068-4_7.

SHARPE, L. T.; STOCKMAN, A.; JÄGLE, H.; NATHANS, J. Opsin genes, cone photopigments, color vision, and color blindness. **Color vision: From genes to perception**, v. 351, p. 3–52, 1999.

SZELISKI, R. **Computer Vision: Algorithms and Applications**. 2nd. ed. Cham, Switzerland: Springer Nature Switzerland AG, 2022.

WAHAB, N.; ISMAIL, F.; NAWAWI, M. Color transformation method for protanopia vision deficiency using artificial neural network. **Journal of Telecommunication, Electronic and Computer Engineering (JTEC)**, v. 8, n. 11, p. 29–33, 2016.

ZHANG, X.; ZHANG, M.; ZHANG, L.; SHEN, P.; ZHU, G.; LI, P. Recoloring image for color vision deficiency by gans. In: **2019 IEEE International Conference on Image Processing (ICIP)**. [*S. l.*: *s. n.*], 2019. p. 3267–3271.

ZHOU, L.; ZHANG, L.; KONZ, N. Computer vision techniques in manufacturing. **IEEE Transactions on Systems, Man, and Cybernetics: Systems**, v. 53, n. 1, p. 105–117, 2023.